


Un pipeline para que los datos **fluyan**.

LA PREGUNTA DE NEGOCIO

¿Cuánto sube la demanda eléctrica peninsular por cada grado de temperatura, y a qué horas se paga más cara esa energía?

El recorrido del dato

Dos fuentes públicas independientes que solo tienen una cosa en común: la hora. Cruzarlas es el trabajo.



Las dos fuentes se ingieren por separado y aterrizan crudas en S3: si mañana cambia el esquema de una, la otra sigue funcionando. El cruce por hora ocurre una sola vez, en Glue, y a partir de ahí ya hay una única tabla que responde la pregunta.

Qué hace cada etapa, y por qué

Seis etapas. Ninguna está ahí por adorno: cada una resuelve un problema que la anterior deja abierto.

01

Fuentes

REE publica demanda y precio horarios;
Open-Meteo publica temperatura horaria.
Ambas abiertas, sin registro.

Por qué así: ninguna pide token, así que el proyecto arranca hoy en vez de esperar días a que alguien conteste un correo.

02

Ingesta

Una Lambda por fuente. Piden un rango de fechas, reintentan con backoff y escriben la respuesta sin tocarla.

Por qué así: la API de REE devuelve errores 400 intermitentes aunque la petición sea correcta. Sin reintentos, el pipeline es una lotería.

03

S3 raw

El JSON original, tal cual llegó, particionado por fecha de ingesta. No se transforma nada aquí.

Por qué así: si mañana descubro un fallo en la transformación, puedo reprocesar desde el origen sin volver a pedir nada a la API.

04

Transformación

Glue con PySpark: aplanar el JSON, validar rangos, normalizar zonas horarias y unir las tres series por hora.

Por qué así: el *join* es el corazón del proyecto. Y las horas vienen con offset (+01:00 / +02:00): si no se normaliza, marzo y octubre salen mal.

05

S3 curated

Una tabla en parquet, particionada por año/mes/día, lista para consultar.

Por qué así: Athena cobra por terabyte escaneado. Parquet más particiones convierte un escaneo completo en leer solo los días que preguntas.

06

Consulta

Glue Data Catalog registra el esquema y Athena lo consulta con SQL corriente.

Por qué así: cierra el círculo. El dato deja de ser un archivo en un bucket y pasa a ser algo a lo que el negocio le puede preguntar.

Las decisiones de esta fase

Cuatro cosas que podrían haber sido de otra manera, y el motivo de que no lo sean.

01 apidatos en vez de ESIOS

ESIOS da los mismos datos pero exige un token que se pide por correo y tarda días. `apidatos.ree.es` es pública y devuelve lo mismo ahora mismo. Elegir la fuente que no te bloquea es una decisión de arquitectura, no un atajo.

02 Dos fuentes, no una

Con solo los datos de REE esto sería un copiadador de ficheros. Meter la temperatura obliga a resolver esquemas distintos, zonas horarias y un cruce por clave — que es exactamente el trabajo real de un pipeline.

03 Step Functions, no Airflow

MWAA cuesta unos cientos de euros al mes aunque no lo uses. Step Functions se paga por transición y aquí sale prácticamente gratis. Airflow se justifica con decenas de DAGs; con tres pasos, no.

04 Raw y curated separados

Podría transformar al vuelo y guardar solo el resultado. Pero entonces cada fallo en la lógica significaría volver a pedirle todo el histórico a una API que ya falla sola. El raw es el seguro.

Lo que hay que vigilar

- **Glue es el único servicio del stack que puede dar un susto**

S3, Lambda, Step Functions y Athena caben de sobra en capa gratuita con este volumen de datos — hablamos de kilobytes por día.

Glue no tiene capa gratuita. Se factura por DPU-hora con un mínimo por ejecución. Un job en bucle o —el clásico— un *crawler* dejado en *schedule* es lo que se come el presupuesto. Por eso: mínimo de DPUs, crawlers bajo demanda y nunca programados, presupuesto con alerta configurado *antes* de crear nada, y `terraform destroy` al cerrar cada sesión de pruebas.

Ambas APIs verificadas antes de dibujar nada. Los datos de ejemplo son de una llamada real al 1 de marzo de 2024.

FUENTE	ENDPOINT	AUTENTICACIÓN	RESPUESTA
REE · demanda	/demanda/evolucion	ninguna	200 · 24 puntos/día
REE · precio	/mercados/precios-mercados-tiempo-real	ninguna	200 · PVPC + spot
Open-Meteo	/v1/archive	ninguna	200 · 24 puntos/día